

FPT UNIVERSITY
ARTIFICIAL INTELLIGENCE DEPARTMENT



FPT UNIVERSITY

REPORT PROJECT 3 - GROUP 5

SUBJECT: DPL302m
CLASS: AI1902 - AA
LECTURER: Hieubv10

FULL NAME	ROLL NUMBER
Lê Minh Hoàng	HE191422
Tạ Bảo Ngọc	HE191387
Trần Trọng Nghĩa	HE190336
Bùi Văn Long	HE190896

HOA LAC, JULY 2025

I. Giới thiệu

Nhận diện cảm xúc qua giọng nói (Speech Emotion Recognition – SER) là một bài toán nhằm phát hiện và phân loại cảm xúc của con người thông qua các đặc trưng âm thanh trong giọng nói. Trong bài toán SER, các tín hiệu âm thanh đầu vào sẽ được tiền xử lý để trích xuất đặc trưng – điển hình là các hệ số MFCC (Mel Frequency Cepstral Coefficients), sau đó được đưa vào mô hình học máy hoặc học sâu để nhận diện cảm xúc như vui vẻ, buồn bã, tức giận, sợ hãi, v.v. Các mô hình phổ biến có thể kể đến bao gồm MLP, CNN, RNN, LSTM và các kiến trúc hiện đại hơn như Transformer.

Báo cáo này trình bày quá trình xây dựng hệ thống SER sử dụng dữ liệu âm thanh, bao gồm các bước tiền xử lý dữ liệu, trích xuất đặc trưng MFCC, huấn luyện mô hình LSTM, tinh chỉnh siêu tham số và đánh giá độ chính xác của mô hình trên tập kiểm tra. Mục tiêu là xây dựng một mô hình có khả năng phân loại cảm xúc một cách chính xác và tổng quát.

II. Phương pháp

- Chia ra làm 2 mô hình (có augmented data và không có augmented data) từ đó so sánh và đánh giá hiệu quả khi augment data tác động lên cùng 1 cấu trúc mạng, cấu trúc mô hình
- SER là bài toán multi-class với input là file âm thanh (.wav) và cho ra output là 1 trong các nhãn cảm xúc. Các bước gồm có:
 - a) Với mô hình sử dụng cả augmented data:
 1. **Tiền xử lý - xử lý:** xử lý thống nhất nhãn giữa các datasets và chia tập train, dev, test
 2. **Augment data:** augment data trên tập train ở các nhãn có tần suất xuất hiện ít hơn so với các nhãn còn lại
 3. **Trích xuất đặc trưng:** trích xuất ra MFCC ở cả 3 tập train, dev, test giúp mô hình học ổn định hơn. Việc học đặc trưng như vậy cũng yêu cầu tập dev và test cũng phải biến đổi đầu vào
 4. **Encode label:** chuyển các nhãn văn bản thành vector one-hot encoding
 5. **Train model:** Sử dụng kiến trúc 2 lớp CNN, 1 lớp LSTM, 1 lớp output

6. **Evaluate**: Dùng accuracy, vẽ biểu đồ tập train - val, confusion matrix

b) Với mô hình **không** sử dụng augmented data:

1. **Tiền xử lý - xử lý**: tương tự như trên
2. **Trích xuất đặc trưng MFCC**: tương tự như trên
3. **Encode label**: tương tự như trên
4. **Train model**: tương tự như trên
5. **Evaluate model**: tương tự như trên

III. Chi tiết phương pháp

- Dataset sử dụng là concat của 4 tập:

- 1) [Crema_D](#)
- 2) [RAVDESS](#)
- 3) [SAVEE](#)
- 4) [TESS](#)

- 4 dataset này biểu lộ cảm xúc qua giọng nói chứ không qua câu chữ ngữ nghĩa của câu
- 8 loại nhãn cảm xúc: fear, happy, disgust, sad, surprise, calm, neutral, angry

a) **Tiền xử lý - xử lý dữ liệu**: Load data, xử lý và quy chung về nhãn giống nhau (VD: ‘hap’ => “happy”, “fea” => “fear”, v.v).

- Chia tỉ lệ train - dev - test theo tỉ lệ 70 - 15 - 15

b) **Augment data (tùy model)**: lấy mảng dữ liệu sóng âm 1D và giữ nguyên tần số lấy mẫu. Có 3 phương pháp để augment:

- 1) Add noise (thêm nhiễu): sinh nhiễu ngẫu nhiên(Gaussian) và cộng trực tiếp vào âm thanh giúp mô phỏng tiếng gió, quạt, v.v
- 2) Time stretching (kéo giãn thời gian): làm chậm tín hiệu còn 0.8 tức nói chậm đi, đồng thời cắt ngắn đi để khớp độ dài gốc
- 3) Pitch shifting (dịch cao độ): tăng cao độ lên 4 bán âm tức nghe giọng sẽ cao hơn

- Cuối cùng, tạo và lưu ra file có dạng: {đầu_file_gốc_bỏ_đuôi_wav} + {loại nhiễu (noise/stretch/pitch)} + “.wav”

c) **Trích xuất đặc trưng MFCC**: trích 40 giá trị đặc trưng, chia âm thanh thành các đoạn nhỏ khoảng 25 ms. Mỗi đoạn 25ms như vậy được gọi là 1



frame và có tối đa 862 frame. Nếu ít hơn 862 thì pad thêm 0 còn nhiều hơn thì cắt bớt cho còn 862 (chuẩn hóa độ dài)

- X_{train} có cỡ (m, 40, 862) với m là số mẫu
- d) **Encode nhãn:** Chuyển các nhãn dạng chuỗi (VD: "happy", "angry") thành dạng số (0, 1, 2, ...) rồi thành vector one-hot để mô hình sử dụng.
- e) **Train model:** input có cỡ (40,862,1), sử dụng các lớp:
- CNN thứ nhất: tìm các đặc trưng cục bộ dùng hàm relu dùng cả batchNorm, MaxPooling2D cỡ 2x2, Dropout với tỉ lệ 0.3, 32 filters
 - CNN thứ hai: tương tự lớp thứ nhất nhưng tăng số filter lên 64
 - Biến output của CNN (dạng ảnh 4 chiều) → dạng chuỗi 3 chiều để đưa vào LSTM: batch_size, time_steps, features
 - 1 lớp LSTM: xử lý chuỗi thời gian từ đầu đến cuối với dropout = 0.3
 - Lớp output: dùng softmax với số class là số cảm xúc = 8
 - Sử dụng optimizer là Adam, loss là categorical-entropy, EarlyStopping, ReduceLROnPlateau
- f) **Evaluate model:** Đánh giá mô hình qua confusion matrix, biểu đồ accuracy qua các epoch, F1 Score, ...



IV. Kết quả

- Tập train augment có 9872 mẫu, tập train bình thường có 8513 mẫu, còn lại ở 2 tập có dev và test là 1824 mẫu và 1825 mẫu
- Trên tập augment data, thu được accuracy trên test: 51.8356 %

Classification Report:				
	precision	recall	f1-score	support
angry	0.80	0.43	0.56	289
calm	0.39	0.68	0.49	28
disgust	0.47	0.42	0.44	288
fear	0.49	0.45	0.47	289
happy	0.69	0.43	0.53	289
neutral	0.53	0.50	0.51	255
sad	0.39	0.76	0.51	289
surprise	0.74	0.83	0.78	98
accuracy			0.52	1825
macro avg	0.56	0.56	0.54	1825
weighted avg	0.57	0.52	0.52	1825



- Trên tập thường, thu được accuracy trên test: 53.19%



V. Kết luận

- Mô hình khi augment data có cải thiện nhưng không đáng kể (53.84% trên augment và 53.16% trên model no-augment trên cùng tập test cùng phân phối), nếu để đánh đổi từng đấ tài nguyên tính toán cho chỉ một chút độ chính xác như vậy thì mô hình không augment là lựa chọn tốt hơn.
- Đề xuất: Có thể sử dụng thêm nhiều đặc trưng hơn không chỉ mỗi MFCC mà còn có thể sử dụng Chroma_stft, Zero Crossing Rate, RMS value, MelSpectrogram, thay đổi mô hình - kiến trúc mạng (có thể chuyển sang CNN, Neural network). Tham khảo tại: [Speech Emotion Recognition | Kaggle](#) với độ chính xác trên tập test cao hơn (>60%) dù không cùng phân phối, số lượng mẫu test là 25% của cả 4 dataset so với chỉ 15% ở 2 mô hình đã thực nghiệm nêu trên.