

SPEECH EMOTION RECOGNITION


Members

Lê Minh Hoàng - HE191422	Trần Trọng Nghĩa - HE190336
Tạ Bảo Ngọc - HE191387	Bùi Văn Long - HE190896


DATA



- Speech emotion recognition (SER): nhận diện cảm xúc từ giọng nói
- Input là audio (tiếng anh), output là 1 trong các loại cảm xúc như tức giận, ghê tởm, sợ hãi, vui vẻ, bình thường, buồn, ngạc nhiên




- Dataset sử dụng gồm có:
 1. CREMA-D: 7,442 đoạn audio được ghi âm từ 91 diễn viên (48 nam, 43 nữ, tuổi từ 20–74), đa dạng về giới tính và sắc tộc
- Mỗi diễn viên thể hiện 12 câu thoại trong 6 cảm xúc cơ bản: Anger, Disgust, Fear, Happy, Neutral, Sad
- 4 mức độ biểu cảm: Low, Medium, High, hoặc Unspecified
- Tên file theo cấu trúc:
- ActorID_SentenceID_Emotion_Intensity.wav
- → Ví dụ: 1001_DFA_ANG_XX.wav (diễn viên 1001, câu DFA ("Don't forget a jacket"), cảm xúc Angry, mức Unspecified)




2. RAVDESS (Ryerson Audio-Visual Database of Emotional Speech and Song) gồm 7,356 file, ghi âm bởi 24 diễn viên chuyên nghiệp (12 nam, 12 nữ) giọng Bắc Mỹ

- Mỗi diễn viên đọc 2 câu thoại đặt sẵn:
 1. "Kids are talking by the door"
 2. "Dogs are sitting by the door"
- Emotions (speech): neutral, calm, happy, sad, angry, fearful, disgust, surprised.
- Song emotions: calm, happy, sad, angry, fearful.
- Mỗi cảm xúc được biểu hiện ở 2 mức độ: normal, strong (trừ neutral chỉ normal)
- XX-YY-ZZ-PP-QQ-RR-AA.wav
- ZZ = emotion (ví dụ 05 là angry, 06 fearful...)
- PP = intensity
- QQ = câu thoại
- AA = actor ID (01–24, chẵn là nữ)



3. SAVEE (Surrey Audio-Visual Expressed Emotion) gồm 480 đoạn thoại, mỗi diễn viên đọc khoảng 120 câu ngắn


- 7 cảm xúc cơ bản: angry, disgust, fear, happy, neutral, sadness, surprise



4. TESS (Toronto Emotional Speech Set) gồm 2,800 lời nói, mỗi người đọc 200 từ mục tiêu trong 7 trạng thái cảm xúc

- Bởi 2 nữ diễn viên (26 và 64 tuổi, giọng Bắc Mỹ) tại Đại học Toronto
- 1 tập 200 từ mục tiêu được nói theo kiểu 'Say the word ...'
- Cấu trúc tên file:
<voice>_<word>_<emotion>.wav,
ví dụ OAF_back_angry.wav với
OAF là giọng nam, YAF là giọng
nữ

Emotion Distributions in the TESS Dataset




MFCCs

- **MFCC (Mel-Frequency Cepstral Coefficients)** là một tập hợp các hệ số đặc trưng được trích xuất từ tín hiệu âm thanh
- MFCC dựa trên cảm nhận thính giác của con người – vốn không thể cảm nhận rõ các tần số trên 1 kHz



MFCCs




A/D Conversion

Âm thanh là dạng tín hiệu liên tục (analog), trong khi đó máy tính làm việc với các con số rời rạc (digital)

A/D conversion là bước đầu tiên, chuyển tín hiệu âm thanh thực tế (analog) thành dạng số (digital) để xử lý.



A/D Conversion




Quá trình gồm 2 bước chính:

- Sampling: Ghi lại biên độ của tín hiệu tại các thời điểm cách đều nhau
- Quantization: Làm tròn biên độ mẫu



Pre-emphasis

Tín hiệu giọng nói tự nhiên có **tần số cao** thấp hơn nhiều so với **tần số thấp**. Trong khi đó, các tần số cao này vẫn chứa nhiều thông tin về các đặc trưng quan trọng của phụ âm





Pre-emphasis làm tăng cường thành phần tần số cao trong tín hiệu, giúp cải thiện khả năng học và phân tích giọng nói của hệ thống MFCC



Pre-emphasis

$$x'[t_d] = x[t_d] - \alpha x[t_d - 1]$$

$$0.95 < \alpha < 0.99$$



Bộ lọc pre-emphasis trong miền z (Z-domain):

$$H(z) = 1 - az^{-1}$$



Framing

Thay vì biến đổi Fourier trên cả đoạn âm thanh dài, ta trượt 1 cửa sổ dọc theo tín hiệu để lấy ra các frame rồi mới áp dụng DFT trên từng frame này.




Image from Bryan Pellom

Windowing

Windowing là quá trình nhân từng đoạn (frame) của tín hiệu với một hàm cửa sổ (window function) để làm giảm nhiễu biên (spectral leakage) khi thực hiện biến đổi Fourier (DFT).

$$x_w[n] = x[n] \cdot w[n]$$

Trong đó:

- $x[n]$: tín hiệu gốc tại frame
- $w[n]$: window function
- $x_w[n]$: tín hiệu sau khi áp dụng windowing

Rectangular

$$w[n] = 1$$

Hamming





$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right)$$

Hann



$$w[n] = 0.5 - 0.5 \cos\left(\frac{2\pi n}{N-1}\right)$$



2: Phổ lý tưởng (DFT gốc)



1: Tín hiệu đầu vào



DFT

- DFT là bước chuyển đổi từ miền thời gian sang miền tần số
- Trên từng frame, ta áp dụng DFT theo công thức:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j \frac{2\pi}{N} kn}, \quad k = 0, 1, \dots, N - 1$$

- $x[n]$: tín hiệu trong miền thời gian
- $X[k]$: tín hiệu trong miền tần số (số phức)
- N : tổng số mẫu (frame length)
- k : chỉ số tần số
- $e^{-j2\pi kn/N}$: các sóng cơ sở sin/cos



DFT

- DFT là bước chuyển đổi từ miền thời gian sang miền tần số
- Trên từng frame, ta áp dụng DFT theo công thức:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j\frac{2\pi}{N}kn}, \quad k = 0, 1, \dots, N-1$$

- $x[n]$: tín hiệu trong miền thời gian
 - $X[k]$: tín hiệu trong miền tần số (số phức)
 - N : tổng số mẫu (frame length)
 - k : chỉ số tần số
 - $e^{-j2\pi kn/N}$: các sóng cơ sở sin/cos
- Sau khi chia tín hiệu thành frame và áp dụng windowing, DFT sẽ:
 - Chuyển tín hiệu từ miền thời gian → miền tần số
 - Từ đó, áp dụng Mel filterbank → log → DCT → ra MFCC

Mel Filterbank


Mel Filter Bank là một tập hợp các bộ lọc (filter) dùng để chuyển phổ tần số (frequency spectrum) sang Mel scale – một thước đo tần số "cảm nhận" theo cách con người nghe.

Tai người không tuyến tính

- Tai rất nhạy với tần số thấp, nhưng mù mờ với tần số cao.
- Nghe chênh lệch từ 100 → 200 Hz rất rõ, nhưng 7000 → 7100 Hz thì gần như như nhau.

Vậy nếu muốn máy hiểu âm thanh như con người, ta phải chuyển tần số theo cách não người nghe.

→ Đó chính là vai trò của Mel Filter Bank.



MEL SCALE

$$\text{mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

- Ở tần số thấp ($f < 1000$ Hz): gần như tuyến tính
- Ở tần số cao: logarit hóa vì tai người kém nhạy

=> biến phổ âm thanh (frequency spectrum) thành dạng mà tai người cảm thấy "tự nhiên hơn". Chuyển phổ FFT → Mel scale giúp mô hình học sâu bắt chước được cơ chế nghe của con người.

- **Mel Filter Bank là một tập hợp các bộ lọc tam giác chồng lấp, được đặt theo thang đo Mel scale, dùng để trích xuất năng lượng âm thanh theo cách con người nghe.**

- **Là tập hợp N bộ lọc tam giác, được đặt chồng lên nhau, trải đều theo Mel scale (chứ không đều theo Hz).**

Mỗi filter:

- **Có 1 đỉnh nằm ở 1 tần số trung tâm (center frequency),**
- **Có 2 điểm chân nằm ở 2 tần số liền trước và liền sau,**
- **Có dạng tam giác cân (thường).**

Quy trình áp dụng

Tín hiệu đầu vào (Waveform)

Âm thanh đầu vào là dạng sóng đã được số hóa, ví dụ tệp .wav, thể hiện biên độ theo thời gian.

Tín hiệu thường được lấy mẫu với tần số như 16000 hoặc 22050 Hz.

2. Chia khung (Framing)

Tín hiệu được chia thành các khung nhỏ (20–40 mili giây) để xử lý ngắn hạn.

Ví dụ: 25ms tại 16kHz tương đương khoảng 400 mẫu.

3. Áp dụng hàm cửa sổ (Windowing)

Mỗi khung được nhân với hàm cửa sổ (như Hamming) để làm trơn biên khung, giúp giảm nhiễu khi biến đổi Fourier.

4. Biến đổi Fourier (FFT)

Áp dụng biến đổi Fourier rời rạc để chuyển tín hiệu từ miền thời gian sang miền tần số.

Kết quả là phổ tần số – thể hiện mức năng lượng tại mỗi tần số.

5. Tính phổ năng lượng (Power Spectrum)

Bình phương độ lớn phổ FFT để tính năng lượng tại từng tần số.

Kết quả là vector năng lượng trên trục tần số tuyến tính.

6. Áp dụng Mel Filter Bank

Tạo các bộ lọc tam giác trải đều trên thang đo Mel.

Mỗi filter “gom” năng lượng từ một dải tần Mel bằng cách lấy tích trọng số với phổ năng lượng.

Kết quả là vector đặc trưng theo Mel scale (ví dụ 40 chiều).

7. Log năng lượng (tùy chọn)

Áp dụng hàm log để giảm chênh lệch năng lượng quá lớn và mô phỏng cảm nhận thực tế của tai người.

8. DCT → MFCC (tùy chọn)

Áp dụng biến đổi cosine rời rạc (DCT) lên log năng lượng Mel để tạo ra các hệ số MFCC.

Giữ lại khoảng 13–20 hệ số đầu tiên làm đặc trưng đầu vào cho mô hình học máy.

PIPELINE

Waveform

- Framing
- Windowing
- FFT
- Power Spectrum
- Mel Filter Bank
- Log (tùy)
- DCT → MFCC (tùy)


Vai trò trong các hệ thống AI âm thanh

Là bước tiền xử lý quan trọng trong:
Speech Recognition (Google Assistant, Siri,...)

Speaker Identification

Music Genre Classification

Emotion detection from voice




- Trục hoành (x-axis): tần số (Hz), từ 0 đến 8000 Hz
- Trục tung (y-axis): biên độ hoặc năng lượng (theo dB hoặc log scale)
- Đường xanh: phổ tần số (FFT) của một đoạn tín hiệu âm thanh
- Các tam giác đỏ: là các bộ lọc Mel (Mel filters) – hay còn gọi là Mel triangular filter
 - Ý nghĩa
 - Mỗi tam giác là một bộ lọc tam giác dùng trong Mel Filter Bank
 - Trục ngang của mỗi tam giác phủ một vùng tần số nhất định
 - Đỉnh tam giác: vị trí tần số trung tâm (center frequency)
 - Độ rộng tam giác: chính là băng thông (bandwidth) của filter
 - "More number of filters in low freq. region"
 - Trong vùng tần số thấp (0–2000 Hz), có nhiều filter được dồn lại sát nhau
 - Điều này thể hiện rằng tai người rất nhạy với tần số thấp
 - Ví dụ: phân biệt giữa các âm /m/, /n/, /b/, /d/ đều nằm ở vùng thấp
 - Vì vậy ta cần nhiều filter nhỏ, phủ kín, phân giải cao trong vùng này
 - "Lesser number of filters in high freq. region"
 - Vùng tần số cao (từ khoảng 4000–8000 Hz): số lượng filter giảm, khoảng cách xa hơn
 - Tức là: ít filter hơn, mỗi cái rộng hơn
 - Điều này mô phỏng thực tế là tai người kém nhạy với tần số cao
 - Hai âm có tần số cách nhau 300 Hz ở vùng 7000 Hz nghe gần như giống nhau
 - Nên ta không cần filter dày đặc tại đây

LSTM

Long Short-Term Memory (LSTM) là một phiên bản cải tiến của mạng nơ-ron hồi tiếp (RNN). LSTM có khả năng ghi nhớ các phụ thuộc dài hạn trong dữ liệu tuần tự, khiến chúng trở nên lý tưởng cho các nhiệm vụ như dịch ngôn ngữ, nhận dạng giọng nói và dự đoán chuỗi thời gian.




LSTM ARCHITECTURE




FORGET GATE

- Thông tin không còn hữu ích trong trạng thái ô (cell state) sẽ bị loại bỏ bởi cổng quên (forget gate).
- Phương trình của cổng quên là:
$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$
- Trong đó:
- W_f là ma trận trọng số liên kết với cổng quên.
[h_{t-1}, x_t] là phép nối giữa đầu vào hiện tại (x_t) và trạng thái ẩn trước đó (h_{t-1}).
- b_f là độ lệch (bias) của cổng quên.
- σ là hàm kích hoạt sigmoid.




INPUT GATE

- Việc thêm thông tin hữu ích vào trạng thái ô (cell state) được thực hiện thông qua cổng đầu vào (input gate). Đầu tiên, thông tin được điều chỉnh bằng hàm sigmoid để lọc ra các giá trị cần ghi nhớ, tương tự như cổng quên.
- Các phương trình của cổng đầu vào là:
$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$
$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$



OUTPUT GATE

- Nhiệm vụ trích xuất thông tin hữu ích từ trạng thái ô hiện tại để đưa ra đầu ra (output) được thực hiện bởi cổng đầu ra (output gate).
- Phương trình của cổng đầu ra là:
$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$
$$h_t = o_t \times \tanh(C_t)$$



SPEECH THERAPY



Students who have difficulties with stuttering, articulation, or voice receive speech therapy.



SAY GEX

Stuttering

- Speaking smoothly without hesitating, stopping, or repeating sounds, words, or phrases.

Articulation

- Producing speech sounds correctly.
- Speaking clearly, and being intelligible to others.

Voice

- Using a voice that doesn't sound raspy or nasal.
- Using a volume that is too loud or too soft.

SPEECH VS. LANGUAGE

In therapy, speech-language pathologists primarily work on speech and language.

Olivia Wilson, M.S., CCC-SLP



SLP stands for
speech-language
pathologist

WHAT'S GAY?



You have a 3rd grader who substitutes /w/ for /r/. They might say words like, "wabbit" or "weady".

Is that speech or language therapy?

Your 2nd grade student uses short and choppy sentences or incomplete sentences, such as, "Give car him".

Is that speech or language therapy?

Language Therapy

- The student is having difficulty expressing their thoughts, wants and needs in an age-appropriate way.
- Expressive language therapy may be helpful.



Your kindergarten student repeats the initial sounds of words or whole words, such as "Ssssnake" or "I can-can-can do it."

Is that speech or language therapy?

Speech Therapy

- The student is having difficulty using smooth and fluent speech, which affects their ability to communicate.
- Stuttering therapy might be helpful.



Speech Therapy

- The student is having difficulty using smooth and fluent speech, which affects their ability to communicate.
- Stuttering therapy might be helpful.



Your student usually responds to your questions with answers that do not relate to the question.

Is that speech or language therapy?

Language Therapy

- The student is having difficulty understanding spoken language.
- Because it is difficult for them to process incoming information, they can't respond to questions appropriately.
- Receptive language therapy may be necessary.





IN CLOSING...

If you have questions about speech and language therapy, please send me an email.

hello@reallygreatsite.com

Olivia Wilson, M.S., CCC-SLP



THANK YOU!

Olivia Wilson, M.S., CCC-SLP